



FACULTAD DE
CIENCIAS EXACTAS
UNICEN

INFORME TRABAJO FINAL INVESTIGACIÓN OPERATIVA 2025
MINERÍA DE DATOS Y TÉCNICAS DE CLUSTERING PARA PREDECIR
DESERCIÓN UNIVERSITARIA

Integrantes

Clementi, Gonzalo
Salías, Leandro Gabriel

Director

Illescas, Gustavo

**Facultad de Ciencias Exactas, Universidad Nacional del Centro de
la Provincia de Buenos Aires**

Emails

gonzaloclementi@gmail.com
leandrosalias42@gmail.com

MINERÍA DE DATOS Y TÉCNICAS DE CLUSTERING PARA PREDECIR DESERCIÓN UNIVERSITARIA

GONZALO CLEMENTI, LEANDRO SALIAS

Facultad de Ciencias Exactas - Universidad Nacional del Centro de la Provincia de Buenos Aires (UNICEN)

gonzaloclementi@gmail.com, leandrosalias42@gmail.com

RESUMEN

La deserción universitaria constituye un desafío central en la educación superior, especialmente en carreras de informática y sistemas, donde las tasas de abandono son elevadas. Este estudio analiza el caso de la carrera de Ingeniería en Sistemas de la Facultad de Ciencias Exactas (UNICEN) utilizando minería de datos aplicada a cohortes entre 2011 y 2023. Se construyeron variables académicas clave a partir del sistema SIU Guaraní y se definió la condición de deserción mediante criterios objetivos de inactividad y rendimiento. Para identificar factores de riesgo se aplicó regresión logística penalizada (LASSO), mientras que el clustering jerárquico permitió segmentar perfiles estudiantiles validados con el índice Silhouette.

Los resultados muestran que el tiempo transcurrido desde el último examen, el porcentaje de finales aprobados y la inactividad reciente son los predictores más influyentes del abandono. Además, el 62,3% de los desertores provenía de fuera de la ciudad de Tandil y el 77,2% no aprobó materias clave en los primeros años, lo que sugiere la importancia de factores contextuales y académicos iniciales. La clasificación obtenida permitió diferenciar trayectorias de alto rendimiento, avance intermedio y abandono crónico. Se concluye que estas técnicas ofrecen un marco eficaz para diseñar alertas tempranas e intervenciones institucionales que mitiguen la deserción.

PALABRAS CLAVE

Minería de datos educativos; Deserción universitaria; Clustering jerárquico; Regresión logística LASSO; Aprendizaje automático en educación; Predicción del abandono estudiantil; Factores de riesgo académico; Retención universitaria.

ABSTRACT

University dropout is a major challenge in higher education, particularly in computer science and systems-related degrees, where attrition rates remain high. This study focuses on the case of the Systems Engineering program at the Faculty of Exact Sciences (UNICEN), analyzing cohorts from 2011 to 2023 through educational data mining techniques. Academic variables were built from the SIU Guaraní database, and dropout status was defined using objective criteria of inactivity and academic performance. Penalized logistic regression (LASSO) was applied to identify the most relevant predictors, while hierarchical clustering, validated with the Silhouette index, was used to segment student profiles.

The results indicate that time since the last exam, the percentage of completed finals, and recent inactivity are the strongest predictors of dropout. Furthermore, 62.3% of dropouts were students from outside Tandil, suggesting an influence of living costs, while 77.2% failed to pass key programming-related subjects during the early years of study, highlighting the impact of foundational courses. The clustering analysis revealed heterogeneous profiles, ranging from students with strong persistence to those with chronic or early abandonment. These findings confirm the usefulness of data mining for designing early-warning systems and institutional strategies to reduce dropout rates.

KEY WORDS

Educational data mining; University dropout; Hierarchical clustering; LASSO logistic regression; Machine learning in education; Student dropout prediction; Academic risk factors; University retention.

1. INTRODUCCIÓN

Con el auge de la tecnología en el siglo XXI, se produjo un incremento significativo en la elección de estudios de grado relacionados al desarrollo de software y sistemas. Particularmente en Argentina, se intensificó a partir del año 2016, superando en ritmo al resto del sistema educativo [1]. Este fenómeno está impulsado por el creciente papel de la digitalización, la automatización y el uso generalizado de tecnologías emergentes, como la inteligencia artificial, así como también por las salidas laborales inmediatas y los salarios competitivos que ofrecen estos puestos de trabajo [2].

Teniendo en cuenta el aumento en la matrícula de estas carreras, surge una problemática que afecta a universidades de todo el mundo: la deserción estudiantil. Entre las definiciones más influyentes, Tinto (1975) la conceptualiza como un proceso longitudinal en el que el estudiante interactúa con la institución y toma la decisión de continuar o abandonar sus estudios en función de su nivel de integración [3]. Es decir, no sólo se tienen en cuenta factores académicos, sino también factores sociales (vínculos, amistades, redes de apoyo, interacción con docentes y pares).

Para esta investigación, se analizó la parte académica del problema en base a un trabajo de investigación realizado anteriormente. Palacios J. y Romero J. aplicaron técnicas de data mining y machine learning para estudiar grupos de alumnos de la cohorte 2018 de la carrera de Ingeniería de Sistemas de la Facultad de Ciencias Exactas de la Universidad Nacional del Centro de la Provincia de Buenos Aires. En dicho estudio, se empleó clustering jerárquico aglomerativo, una técnica utilizada para agrupar datos no etiquetados y construir perfiles que permitan extraer conclusiones sobre los datos inicialmente recolectados [4].

El presente trabajo tiene como objetivo continuar esta línea y profundizar en las posibles causas de deserción. En primer lugar, se aplicó regresión logística con

penalización LASSO sobre las variables que se obtuvieron a partir del análisis preliminar (finales aprobados, días transcurridos desde el ingreso, días desde el último final rendido, entre otras) para evaluar el peso de cada una sobre la deserción. Posteriormente, se utilizó clustering jerárquico aglomerativo para definir grupos que permitieron definir perfiles de alumnos con riesgo de abandono. Por último, se analizaron los resultados obtenidos para obtener conclusiones, y se propusieron lineamientos a seguir que orienten futuras investigaciones en el área.

Algunos estudios relacionados utilizaron técnicas similares a las aplicadas a esta investigación: [8] realizó data mining sobre los datos del sistema SIU-Guaraní para descubrir reglas que caractericen al abandono; [9] y [10] emplearon clustering jerárquico y otras técnicas de agrupamiento no supervisadas para crear perfiles de estudiantes universitarios desertores y comparar los resultados de las distintas técnicas; y [11] aplicó regresión logística LASSO para predecir deserción universitaria.

2. ANÁLISIS PRELIMINAR DE LOS DATOS

2.1 ANÁLISIS DE LOS DATOS PROVISTOS EN EL DATASET ORIGINAL

El conjunto de datos de la matrícula de alumnos fue extraído del sistema SIU Guaraní. La base de datos se encuentra estructurada en múltiples tablas que registran la totalidad de los estudiantes, incluyendo sus cursadas, exámenes finales y asignaturas rendidas.

Aplicando técnicas de data mining se realizó un preprocesamiento de los datos originales para reducir el ruido y facilitar la creación de variables que permitan analizar y determinar si un alumno abandonó la carrera o no.

El dataset original contenía datos de toda la matrícula de la Facultad de Ciencias Exactas. Para realizar esta investigación se seleccionó a los estudiantes de la carrera de Ingeniería de Sistemas que se anotaron entre los años 2011 y 2023, para concentrar a los alumnos de los planes de estudio 2011 y 2022 (planes que actualmente aún se cursan).

Uniando los datos de los alumnos con los correspondientes a sus exámenes (parciales y finales), se obtuvieron las variables que se utilizaron en el proceso de investigación de la deserción, las cuáles pueden observarse en la Tabla 1.

Nombre de la variable	Descripción
tiempo_desde_ingreso	Tiempo desde que ingresó a la carrera en días
cursadas_aprobadas	Cantidad de cursadas aprobadas
cursadas_regulares	Cantidad de cursadas regulares
cursadas_promocionadas	Cantidad de cursadas promocionadas
cursadas_desaprobadas	Cantidad de cursadas desaprobadas
notas_cursadas_ult_anio	Es una nota promedio de las cursadas que realizó el alumno en el último año.
materias_annotado_ult_anio	Cantidad de materias anotadas en el último año
porc_cursadas	Porcentaje promedio de cursadas realizadas
finales_aprobados	Cantidad de finales aprobados
finales_desaprobados	Cantidad de finales desaprobados
dias_dsd_ultimo_final	Días desde que rindió el último final
total_materias_finalizadas	Cantidad de materias totales finalizadas
porc_finales	Porcentaje promedio de finales realizados

Tabla 1. Nombre de la característica y descripciones correspondiente del conjunto de datos experimentado.

2.2 ANÁLISIS DE LA VARIABLE DESERTO

La variable “deserto” se definió para caracterizar a los estudiantes que abandonaron la carrera. Ésta es binaria y puede adquirir los siguientes valores:

- **True (Si desertó):** Cuando el estudiante cumple al menos una de las condiciones establecidas en el criterio de deserción
- **False (No deserto):** Cuando el estudiante no cumple ninguna de las condiciones.

El criterio que se consideró para clasificar a los estudiantes, se tuvo en cuenta cuatro indicadores:

- 1) **Inactividad en exámenes finales:** El alumno no se inscribió a un examen final en un periodo mayor a 730 días (2 años)
- 2) **Bajo porcentaje de finales aprobados:** Menos del 50% de finales aprobados
- 3) **Falta de inscripción en materias:** ausencia de inscripción en cursadas en el último año académico
- 4) **Condición administrativa:** el registro institucional del SIU Guaraní, tiene calidad académica “**Abandono**”

Este criterio cuenta con una medida objetiva y ajustada a la realidad académica. De este modo la variable “deserto” permite identificar con precisión a los estudiantes que han abandonado la carrera, diferenciándolos de aquellos que, aunque con bajo rendimiento, aún mantienen actividad académica.

3. TÉCNICAS UTILIZADAS

3.1 REGRESIÓN LOGÍSTICA PENALIZADA (LASSO)

La regresión logística penalizada (LASSO) sirve para predecir la probabilidad de un evento binario (p. ej., deserción: sí/no) y, al mismo tiempo, seleccionar automáticamente las variables más relevantes. Es una logística a la que se le agrega una penalización que pone un “costo” por usar demasiadas variables; las menos útiles quedan con coeficiente cero, dejando un modelo simple y explicable. [6]

Se utilizó esta técnica porque existen muchos predictores (materias aprobadas, reprobadas, tiempo desde ingreso, % de finales, etc.) y varios están correlacionados; LASSO reduce ruido y colinealidad, evitando el sobreajuste y mejorando la capacidad de generalizar. Además, la deserción es multicausal (factores académicos, socioeconómicos, laborales y de cuidado), por lo que un enfoque con selección automática ayuda a priorizar los determinantes más influyentes. [7]

Esta técnica se empleó para pasar de describir perfiles a cuantificar qué variables empujan más el rendimiento/abandono y priorizar acciones de intervención (alertas, tutorías, operación egreso), sosteniendo el modelo logístico ya utilizado en estudios locales y ampliándolo con regularización L1 para una mejor parsimonia del modelo. [6]

3.2 CLUSTERING JERÁRQUICO

El clustering jerárquico agrupa observaciones construyendo una estructura anidada que se visualiza en un dendrograma, sin necesidad de fijar de antemano el número de clústeres; esto permite elegir luego un corte interpretable.

Esta técnica fue seleccionada porque es estable (no depende de inicializaciones aleatorias como k-means), facilita descubrir subgrupos con patrones diferentes de avance/deserción y se ajusta al objetivo descriptivo/diagnóstico del estudio, con validación posterior vía Silhouette score.

Se usó distancia “euclídea” para la matriz ya que es compatible con el método de enlace “ward.D2” [5], el cual requiere una métrica que preserve las propiedades geométricas del espacio de datos, garantizando resultados coherentes y robustos.

Para el enlace se adoptó “ward.D2” ya que minimiza el incremento de varianza intra-clúster en cada fusión y genera grupos más compactos y

balanceados; además, es la variante que preserva el criterio de Ward en implementaciones modernas. [6]

Se reemplazó “complete” porque, al basarse en el diámetro máximo, tiende a fragmentar grupos grandes y en nuestros datos produjo peor Silhouette y particiones menos equilibradas, mientras que ward.D2 mantuvo la uniformidad del dendrograma y un desempeño global superior.

3.2.1 CORTE DEL DENDROGRAMA

Para cortar el dendrograma se utilizó el método de Silhouette score. Éste mide qué tan cerca están los puntos dentro del mismo clúster y qué tan lejos está un clúster de los demás.

El índice de Silhouette para un punto i es:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

donde:

$a(i)$: la distancia promedio de i a todos los demás puntos de su mismo clúster.

$b(i)$: la distancia promedio de i al clúster más cercano que no es el suyo.

$s(i)$ cercano a 1 $\rightarrow$ el punto está muy bien asignado (dentro de su clúster y lejos de los demás).

$s(i)$ cercano a 0 $\rightarrow$ el punto está en la frontera entre clústeres.

$s(i)$ negativo $\rightarrow$ el punto estaría mejor en otro clúster.

El Silhouette score global se calcula como el promedio de todos los $s(i)$:

$$S = \frac{1}{n} \sum_{i=1}^n s(i)$$

donde n es la cantidad de puntos.




Figura 1. Cálculo de Silhouette score para cada número de clústeres

Se determinó que el número óptimo de clusters que maximizan el promedio del coeficiente de Silhouette es 7 (Figura 1). Por lo tanto, una buena altura para cortar el dendrograma puede ser $h = 35$

Silhouette - Jerárquico

$n = 2587$




Figura 2. Gráfico de Silhouette para el clustering jerárquico realizado

La Figura 2 muestra la calidad de los 7 clústeres obtenidos al cortar el dendrograma en una altura de $h = 35$. El ancho promedio de la silueta es de 0,40, lo que indica una estructura de clústeres moderadamente consistente.

Se observa que algunos grupos presentan buena cohesión y separación, como el clúster 5 ($n = 650$, ancho promedio $\approx 0,68$) y el clúster 7 ($n = 892$, ancho promedio $\approx 0,47$), mientras que otros reflejan menor calidad de agrupamiento, como los clústeres 1, 2 y 4 (ancho promedio $\approx 0,26$ – $0,28$).

La presencia de valores negativos en ciertos individuos sugiere que algunos puntos podrían estar asignados a un clúster subóptimo o cercanos a la frontera entre grupos.




Figura 3. Dendrograma para el clustering jerárquico. Cada clúster está diferenciado con un color distinto.

4. RESULTADOS

4.1 ANÁLISIS DE DESERTORES

El primer análisis realizado fue exclusivamente de los desertores. Se tomaron en cuenta dos factores: la localidad de nacimiento de los alumnos, y por otro lado, si desaprobaron alguna materia pilar de la carrera.

4.1.1 DESERTORES POR LOCALIDAD

Teniendo en cuenta que la carrera de Ing. en Sistemas se realiza en la localidad de Tandil, este es un factor importante ya que esto puede traer desafíos adicionales como costos de vida más altos, por ejemplo alquiler o transporte.

En caso de que el alumno no pueda avanzar en la carrera se traduce en pérdida de dinero y tiempo, lo cual puede llevarlo a desertar con respecto a un alumno nacido en Tandil.

Para este caso desertaron un 62.3% de alumnos que no nacieron en Tandil.

Análisis de desertores por localidad




Figura 4. Gráfico de torta que muestra el análisis de los desertores por localidad

4.1.2 DESERTORES POR DESAPROBACIÓN DE MATERIAS IMPORTANTES

Se consideraron como materias importantes aquellas asociadas a la programación, y que se dictan en los primeros tres años. Estas son Introducción a la Programación I y II, Análisis y Diseño de Algoritmos I y II, y Programación Orientada a Objetos.

Estas asignaturas suelen ser correlativas y la desaprobación de alguna de ellas tiene como consecuencia atrasarse un año en la carrera. Entonces se decidió, a partir de los alumnos que desaprobaron alguna de esas materias, observar cuántos de ellos desertaron.

Se obtuvo como resultado que un 79.1% de los alumnos que desaprobaron alguna asignatura pilar de la carrera terminaron abandonando.

Deserción por desaprobación de materias clave




Figura 5. Gráfico de torta que muestra el análisis de deserción por desaprobación de materias clave de la carrera.

4.2 EVALUACIÓN DE VARIABLES

Para respaldar las causas de abandono de manera estadística, se decidió evaluar cuánta influencia tienen los indicadores obtenidos en el análisis preliminar respecto de la variable desertó.

Previamente se eliminaron todas las variables sin valor numérico y las que consideramos poco relevantes o redundantes para el análisis (como cursadas_regulares y total_materias_finalizadas, por ejemplo).

4.2.1 MATRIZ DE CORRELACIÓN

Para evaluar la congruencia entre las variables independientes y la variable dependiente desertó, primero se realizó una interpretación de los datos que arrojó la matriz de correlación construida previamente a la realización del clustering jerárquico (Tabla 2).

Variable	Correlación con desertó	Interpretación
dias_dsd_ultimo_final	+0.6939	Fuerte correlación positiva: cuanto más tiempo desde el último final, mayor probabilidad de deserción. Muy esperable.
porc_finales	-0.3502	Moderada correlación negativa: cuanto mayor el avance en la carrera, menor probabilidad de deserción.
finales_aprobados	-0.3556	Similar a lo anterior: más finales aprobados → menor deserción.
cursadas_desaprobadas	+0.3148	Correlación moderada: puede sugerir frustración → abandono.
cursadas_aprobadas	-0.2270	Ligera correlación negativa: más aprobadas → menor deserción.
materias_annotado_ult_anio	-0.1830	No estar activo recientemente se asocia con mayor deserción.
tiempo_desde_ingreso	+0.4979	Cuanto más tiempo desde el ingreso, mayor probabilidad de abandonar.
finales_desaprobados	-0.1964	Ligera correlación negativa, posiblemente indica persistencia.
cursadas_promocionadas	+0.0204	No parece tener correlación clara con la deserción.

Tabla 2. Matriz de correlación entre las variables independientes y la variable dependiente desertó.

Además, se buscó encontrar en la misma matriz de correlación, congruencias fuertes entre variables independientes que nos permitirían identificar colinealidades,

que posteriormente se pueden terminar de explicar mediante la aplicación de la regresión logística penalizada (LASSO).

Variables	Correlación	Nota
porc_finales y finales_aprobados	0.9994	Casi perfecta: son casi lo mismo (pueden generar redundancia en modelos).
cursadas_aprobadas y finales_aprobados	0.9095	Alta correlación: puede haber multicolinealidad.
cursadas_aprobadas y porc_finales	0.9095	Muy alta: son dos formas de medir el avance.
días_dsd_ultimo_final y tiempo_desde_ingreso	0.8681	Muy correlacionadas: puede representar “inactividad reciente” combinada con antigüedad.

Tabla 3. Correlaciones fuertes entre las variables tomadas que podrían causar colinealidad en modelos

4.2.2 REGRESIÓN LOGÍSTICA - MODELO LASSO

Se utilizó `set.seed(1)` y `lambda = lambda.min` para calcular coeficientes.

Variable	Coefficiente	Interpretación
tiempo_desde_ingreso	-0.000146	A más tiempo desde el ingreso, se reduce levemente la probabilidad de deserción. Efecto muy pequeño, candidata a descartar.
cursadas_aprobadas	-0.0358	Cada cursada aprobada reduce las chances de deserción.
cursadas_promocionadas	0	No fue seleccionada por el modelo, no aporta valor predictivo estable.
cursadas_desaprobadas	-0.0911	Mayor cantidad de cursadas desaprobadas reducen la probabilidad de deserción. Puede ser ruido, o indicar insistencia a pesar de desaprobado.
materias_anojado_ult_ano	-2.435	Cuanta más actividad se tuvo el último año, más se reduce la chance de desertar. Tiene un efecto muy fuerte con un valor absoluto muy alto.
finales_aprobados	-0.0165	A mayor cantidad de finales aprobados, menor chance de desertar. Tiene efecto leve.
finales_desaprobados	+0.0084	Cuanto más finales desaprobados, aumentan las chances de deserción. Efecto casi nulo.
días_dsd_ultimo_final	+0.0243	A más días sin rendir un final, más probabilidad de deserción.
porc_finales	-10.238	A mayor porcentaje de carrera finalizada, mucho menor riesgo de deserción. Es la variable de mayor valor absoluto, por lo tanto la más influyente.

Tabla 4. Coeficientes e interpretación de variables asociadas al riesgo de deserción en el conjunto de datos estudiado.

4.3 ANÁLISIS DE CLÚSTERES

A partir de las medias de las variables académicas, para cada clúster, podemos crear perfiles de estudiantes que permiten caracterizar desde excelencia activa y trayectorias regulares en progreso, hasta bajo avance activo, casi egreso con inactividad, y abandono temprano/medio o crónico.

Se seleccionaron los clústeres **1, 4 y 7** porque representan los casos más representativos e informativos, teniendo en cuenta el rendimiento y la deserción según las variables analizadas dando resultados característicos.

4.3.1 CLUSTER 1




Figura 6. Dendrograma del cluster 1 (dendrograma de color violeta del cluster general)

- **98 alumnos**
- **Cursadas aprobadas:** 17,8 (alto)
- **Cursadas desaprobadas:** 22,3 (muy alto)
- **Finales aprobados:** 10,3
- **Finales desaprobados:** 5,3
- **Promociones:** casi nulas
- **Porcentaje de finales rendido:** 28,9%
- **Tiempo desde ingreso:** 4339 días (~12 años)
- **Deserción:** 93,8%
- **Último final rendido:** hace más de 6 años

Perfil de estudiante: estudiantes rezagados y en riesgo de deserción

Estudiantes que llevan mucho tiempo en la carrera, aprobaron una buena cantidad de materias pero acumularon también muchos reprobados. Pocos promocionaron y tienen varios intentos fallidos en finales. La mayoría terminó abandonando. Requieren un plan de cierre acelerado (mesas flexibles, reválidas, tutoría).

Posible causa de deserción: Acumulación de muchas materias desaprobadas y largos tiempos desde el ingreso. La frustración académica y el desgaste a lo largo de más de 10 años en la carrera parecen explicar la deserción.

4.3.2 CLUSTER 4




Figura 7. Dendrograma del cluster 4 (dendrograma de color verde del cluster general)

- **Cursadas aprobadas:** 23,7 (muy alto)
- **Cursadas desaprobadas:** 12,7 (moderado)
- **Finales aprobados:** 13,8 (alto)
- **Finales desaprobados:** 5,4
- **Promociones:** 3,3 (significativo)
- **Porcentaje de finales rendidos:** 37% (el más alto)
- **Tiempo desde ingreso:** 2484 días (~7 años)
- **Deserción:** 11,4%
- **Último final rendido:** hace ~2 años

Perfil: Estudiantes avanzados, con trayectoria sólida y cercanos a recibirse.

Estudiantes con alto nivel de avance académico, lograron aprobar gran cantidad de materias y rendir bastantes finales, incluso con varias promociones. Aunque algunos desaprobaron exámenes, la mayoría sigue en carrera y no desertó.

Posible causa de deserción: A pesar de ser estudiantes avanzados, con muchos finales rendidos y materias aprobadas, los desertores de este grupo podrían haber abandonado por factores externos (trabajo, cuestiones personales, cambio de carrera) o por el cansancio acumulado de tantos años de cursada (~7 años).

4.3.3 CLUSTER 7




Figura 8. Dendrograma del cluster 7 (dendrograma de color azul del cluster general)

- **Cursadas aprobadas:** 10,1 (moderado-bajo)
- **Cursadas desaprobadas:** 1,9 (bajo)
- **Finales aprobados:** 10,1 (muy alto en relación a cursadas)
- **Finales desaprobados:** 1,9
- **Promociones:** prácticamente nulas
- **Porcentaje de finales rendidos:** 27%
- **Tiempo desde ingreso:** 1442 días (~4 años)
- **Deserción:** 0%
- **Último final rendido:** hace poco más de 1 año

Perfil: Estudiantes en carrera regular, con progreso estable y buen desempeño en exámenes.

Estudiantes relativamente jóvenes en la carrera, con buen rendimiento en finales y baja cantidad de desaprobados. Aunque no promocionan, rinden finales y aprueban con frecuencia. Ninguno desertó.

Posible causa de deserción: No se detectan desertores en este grupo. El rendimiento académico es estable, con buena tasa de finales aprobados y tiempos de permanencia moderados (~4 años).

5. CONCLUSIONES Y TRABAJOS FUTUROS

El análisis en este trabajo permitió comprender con mayor profundidad los factores asociados a la deserción estudiantil en la carrera de Ingeniería de Sistemas de la Facultad de Ciencias Exactas (UNICEN). Los resultados muestran que la deserción se encuentra fuertemente vinculada a variables académicas cuantificables, destacándose como principales predictores: el tiempo transcurrido desde el último examen final rendido, la cantidad y el porcentaje de finales aprobados, así como la inactividad reciente en cursadas. Por otro lado, las cursadas promocionadas no se mostraron como un posible factor de deserción porque no todas las cursadas de la carrera son promocionables. Si lo fueran, entonces sí sería una variable que mostraría mejor progreso entre un alumno y otro.

El análisis de perfiles a través de clustering jerárquico demostró ser una herramienta eficaz para segmentar a los estudiantes en grupos diferenciados, identificando desde casos de alto rendimiento y persistencia hasta perfiles de abandono temprano o avanzado. Esta clasificación permite a la institución comprender la heterogeneidad de trayectorias y orientar políticas de acompañamiento específicas.

Asimismo, el estudio evidenció la influencia de factores contextuales: por un lado, el 62,3% de los desertores no eran oriundos de la ciudad de Tandil, lo que sugiere que los costos adicionales de manutención y desplazamiento pueden incidir en la decisión de abandonar. Por otro lado, se constató que un 77,2% de los estudiantes desertores no aprobaron al menos una materia considerada clave en los primeros años (Introducción a la Programación I y II, Análisis y Diseño de Algoritmos I y II, Programación Orientada a Objetos), lo cual puede indicar que desaprobado una de esas materias pilares y atrasarse en la carrera es un factor de fuerte influencia a la hora de considerar el abandono.

A partir de lo expuesto, se proyectan diversas líneas de continuidad orientadas a profundizar la investigación. Como primera medida, para que el análisis sea más completo, deberían incorporarse indicadores socioeconómicos y contextuales (costeo de estudios, situación laboral, apoyo familiar, motivación, redes

de apoyo y percepción de dificultad académica). Una vez completados estos datos, aplicar otras técnicas de clustering como K-Means y DBSCAN para contrastar la estabilidad de los perfiles hallados.

A su vez se podría realizar un análisis del impacto de la localidad de origen, en especial de quienes no son de Tandil, junto con los costos de vida y la carga familiar

Para anticipar con mayor precisión la probabilidad de abandono, se podrían utilizar algoritmos de machine learning de tipo supervisado como Random Forest, Gradient Boosting o redes neuronales.

Por último, sería importante realizar el diseño de una herramienta institucional que, basada en los indicadores identificados, permita emitir alertas tempranas sobre estudiantes en riesgo y activar intervenciones preventivas como tutorías, becas, flexibilización de mesas de examen y orientación académica.

REFERENCIAS

- [1] MARINO V. (Coord.), SUSTAS S. E., QUARTULLI D., CURCIO J. (2023): *Por qué estudiamos informática. Indagación sobre trayectorias universitarias: instituciones, estudiantes, género y trabajo*. Fundación Sadosky, Buenos Aires, Argentina.
<https://program.ar/wp-content/uploads/2023/05/Por-que-estudiamos-informatica-Version-Completa.pdf>
- [2] LACHMAN J., LÓPEZ A. F., GÓMEZ ROCA S. (2023): *Patrones y nuevas tendencias en el mercado laboral del software y los servicios informáticos en Argentina*. Organización de Estados Iberoamericanos, Observatorio Iberoamericano de la Ciencia, la Tecnología y la Sociedad. pp. 81-132
<https://ri.conicet.gov.ar/handle/11336/251092>
- [3] TINTO V. (1975): "Dropout from Higher Education: A Theoretical Synthesis of Recent Research". *Review of Educational Research*, vol. 45, pp. 89–125.
- [4] HINOJOSA M., DERPICH I., ALFARO M., RUETE D., CAROCA A., GATICA G. (2022): "Procedimiento de agrupación de estudiantes según riesgo de abandono para mejorar la gestión estudiantil en educación superior". *Texto Livre: Linguagem e Tecnologia*, vol. 15.
<https://doi.org/10.35699/1983-3652.2022.37275>
- [5] MURTAGH F., LEGENDRE P. (2014): "Ward's Hierarchical Agglomerative Clustering Method: Which Algorithms Implement Ward's Criterion?". *Journal of Classification*, vol. 31, pp. 274–295.
https://www.numericalecology.com/Reprints/Murtagh_Legendre_J_Class_2014.pdf
- [6] MACCAGNO A., MANGEAUD A., SOMAZZI C., ESBRY N. (2017): "Modelo predictivo de desgranamiento". Publicado en *La deserción estudiantil en el primer año de la universidad*, Universidad Nacional de Córdoba, Córdoba, Argentina, pp. 89–95. (Ver también Anexo III: Regresión logística, pp. 124–126).

https://www.unc.edu.ar/sites/default/files/Libro%20Deserci%C3%B3n%20PEU-SAA-UNC_1.pdf

[7] MUSSO E., BRIZUELA DEL MORAL F., DI NARANJO A. P., PERENO G., SÁNCHEZ S. (2020): “Deserción universitaria y rendimiento académico en estudiantes trabajadores y/o con hijos a cargo”. *Aportes de la Facultad de Psicología*, vol. 5, nº 8, pp. 119–134. Universidad Nacional de Córdoba.

https://ri.conicet.gov.ar/bitstream/handle/11336/159016/CONICET_Digital_Nro.9031f8f6-5d7a-4ca4-b7a7-cb8fde4d5ff7_A.pdf

[8] KUNA H., GARCÍA MARTÍNEZ R., VILLATORO F. (2010): *Identificación de causales de abandono de estudios universitarios. Uso de procesos de explotación de información*. Universidad Nacional de La Plata.

https://sedici.unlp.edu.ar/bitstream/handle/10915/14198/Identificacion_de_Causales.pdf

[9] CHOQUE V., SOSA V., IBARRA W. (2025): “Characterization of the Dropout Student Profile Using Data Mining Techniques”. Preprint en *ResearchGate*.

https://www.researchgate.net/publication/389099375_Characterization_of_the_Dropout_Student_Profile_Using_Data_Mining_Techniques

[10] MELCHOR F., CONEJERO J. M., FERNÁNDEZ A. J., SÁNCHEZ F., RODRÍGUEZ R. (2025): “An empirical evaluation of clustering processes for early detection of university dropout”. Preprint en *ResearchGate*.

https://www.researchgate.net/publication/389606807_An_empirical_evaluation_of_clustering_processes_for_early_detection_of_university_dropout

[11] VALLABHANENI T. (2019): *Prediction of university student attrition rate using Ridge and Lasso Regression*. Kansas State University, USA.

<https://krex.k-state.edu/server/api/core/bitstreams/ace42cce-f41b-41e8-95a6-7852ed4ab158/content>