Experiencia con DBSCAN

Agrupamiento de estudiantes de Ingeniería de Sistemas

1 Qué es DBSCAN y cómo funciona

DBSCAN agrupa observaciones por densidad: eps define el radio de cercanía y min_samples la cantidad mínima de vecinos, incluido el propio punto, para formar un núcleo. El algoritmo conecta núcleos cercanos y agrega sus puntos de borde; los demás quedan como ruido. Los grupos pueden extenderse mediante cadenas de vecinos, aunque sus extremos sean distintos. La cantidad de grupos surge de los datos y los parámetros, sin fijarse previamente [1, 2].

2 Datos utilizados como entrada

Utilizamos la entrada académica definida para el análisis jerárquico del informe de referencia, conservando sus atributos, filtros y estandarización. En nuestra comparación, DBSCAN, el jerárquico y K-Means recibieron exactamente la misma matriz; no usamos las etiquetas jerárquicas como atributos ni modificamos la entrada para favorecer a un método.

Mantuvimos las diez variables originales, incluido deserto, y calculamos distancias euclídeas sobre sus valores estandarizados. Los casos corresponden a la fecha de análisis del 1 de octubre de 2026. Así, las diferencias observadas se atribuyen al criterio de agrupamiento y a los parámetros, sobre una entrada común.

3 Casos representativos y grupos obtenidos

Seleccionamos cinco casos de la exploración realizada [3]. En cada uno indicamos los parámetros, el resultado y su gráfico. Las barras indican cantidades y porcentajes sobre el total de alumnos, incluido el ruido en gris. En el texto, la concentración del grupo mayor se calcula entre los agrupados, excluyendo el ruido. Las etiquetas no establecen correspondencias entre casos.

Caso 1 Configuración original

En este ejemplo utilizamos eps=1,5 y min_samples=5, los parámetros presentes en el script R original. Obtuvimos un único grupo de 2.393 alumnos y 194 como ruido (7,50 %). El gráfico muestra que la cobertura amplia no produjo una separación entre varios perfiles. Silhouette no pudo calcularse por existir un solo grupo sin ruido.

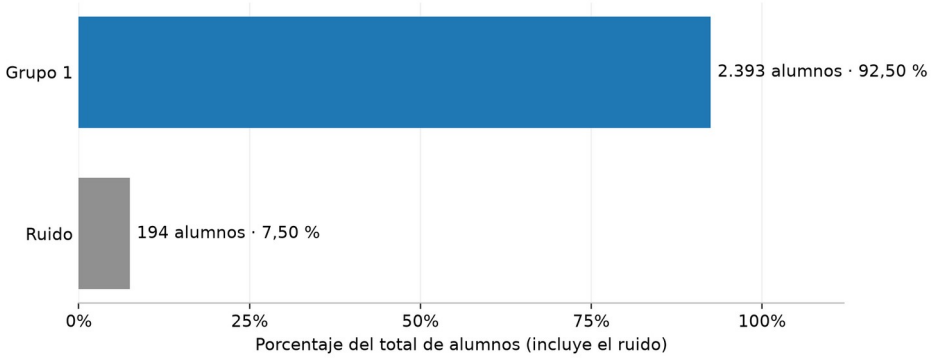


Figura 1 Cantidad y porcentaje del total en el caso 1. Fuente: resultados del proyecto.

Caso 2 Siete grupos con poco ruido

Utilizamos eps=1,175 y min_samples=4. Se formaron siete grupos de 2.215, 85, 28, 5, 4, 4 y 2 alumnos, y 244 quedaron como ruido (9,43 %). El grupo mayor reunió el 94,54 % de los agrupados: tener siete etiquetas no aportó siete perfiles de tamaño relevante.

El grupo de dos alumnos es válido: min_samples exige densidad local para identificar un núcleo, no un tamaño mínimo del grupo final. En este caso, el núcleo tenía cuatro puntos dentro de eps, incluido él mismo. Dos eran puntos de borde ya asignados al grupo 2; el núcleo y el vecino restante formaron el grupo 3. Los bordes compartidos se asignan al grupo que scikit-learn encuentra primero [1].

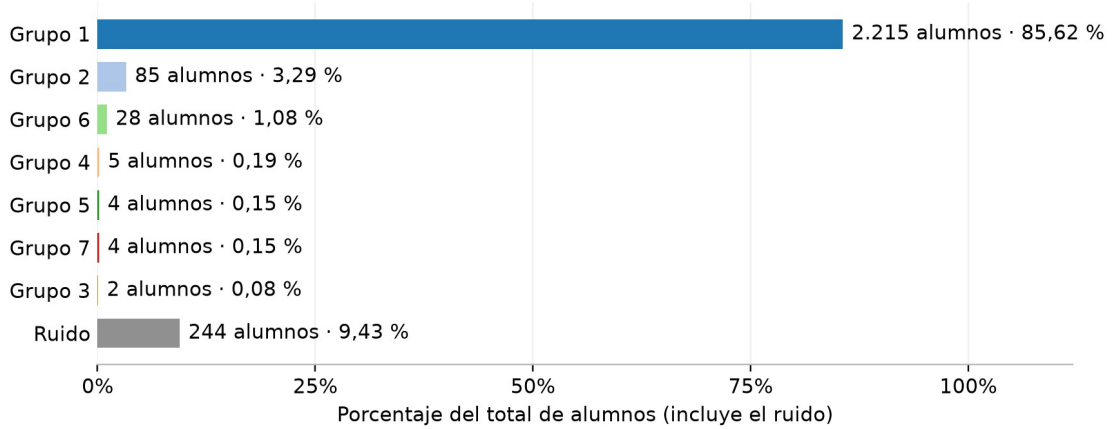


Figura 2 Cantidad y porcentaje del total en el caso 2. Fuente: resultados del proyecto.

Caso 3 Siete grupos con más ruido

Con eps=0,5 y min_samples=10, obtuvimos siete grupos de 1.498, 152, 82, 61, 19, 15 y 11 alumnos. La concentración del mayor bajó al 81,50 %, pero el ruido aumentó a 749 alumnos (28,95 %). El gráfico muestra una separación algo mayor, a costa de excluir más estudiantes.

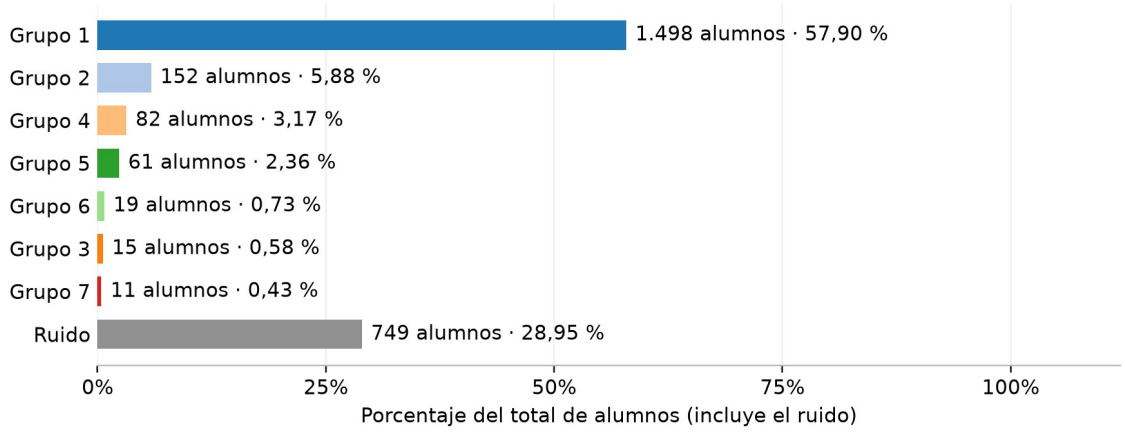


Figura 3 Cantidad y porcentaje del total en el caso 3. Fuente: resultados del proyecto.

Caso 4 Catorce grupos

En este caso mantuvimos eps=0,5 y redujimos min_samples a 6. Se formaron 14 grupos y 632 alumnos quedaron como ruido (24,43 %). El mayor reunió 1.511 alumnos, el 77,29 % de los agrupados. Aumentar la cantidad de grupos tampoco eliminó el predominio de uno sobre los demás.

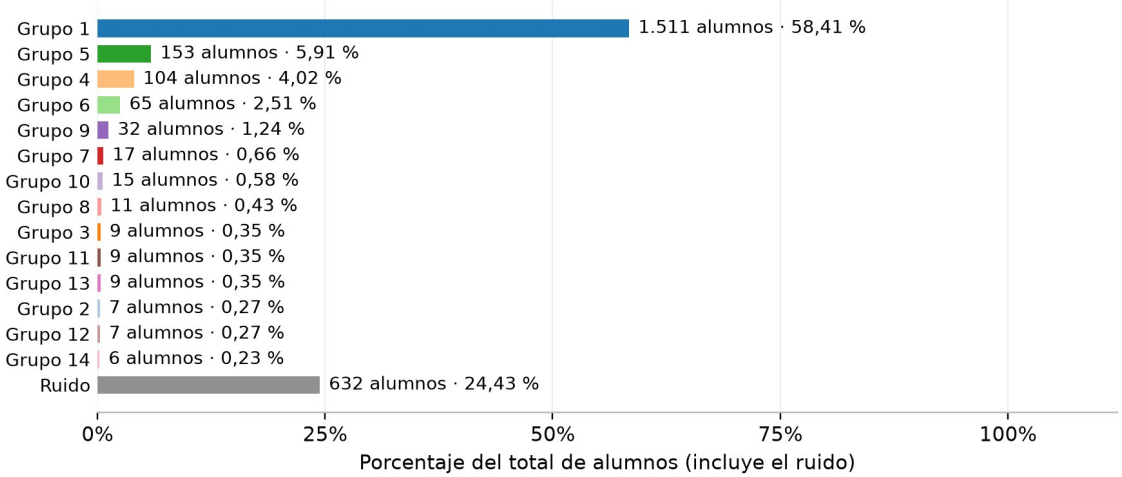


Figura 4 Cantidad y porcentaje del total en el caso 4. Fuente: resultados del proyecto.

Caso 5 Alta fragmentación

Con eps=0,18 y min_samples=5, obtuvimos 59 grupos. El mayor tuvo 544 alumnos, el 38,83 % de los agrupados, pero 1.186 quedaron como ruido (45,84 %). El gráfico muestra los diez grupos mayores y reúne los otros 49 en una barra solo para facilitar la lectura; no es un grupo de DBSCAN. Reducir la concentración implicó fragmentación y exclusión de casi la mitad de la población.

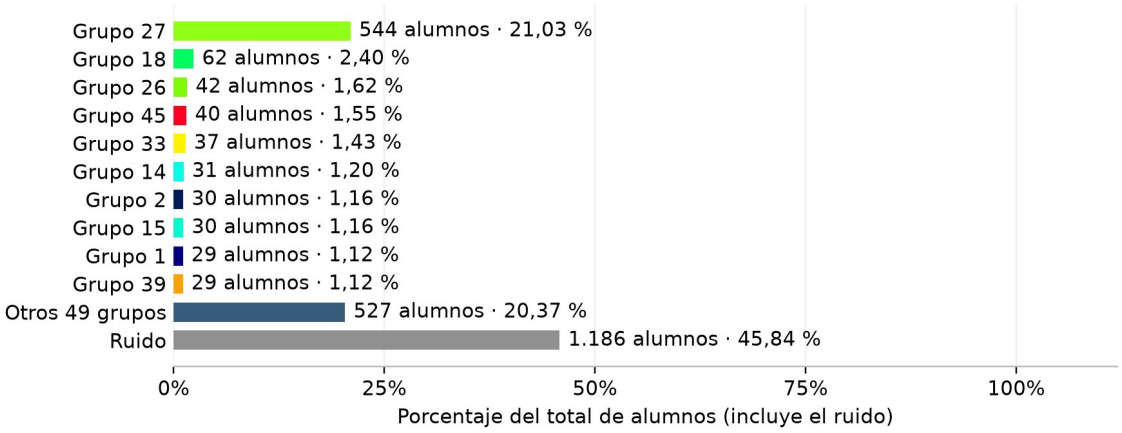


Figura 5 Cantidad y porcentaje del total en el caso 5. Fuente: resultados del proyecto.

Comparación visual de los casos 2 y 5

Las nubes permiten observar dónde se proyectan los grupos y el ruido. Los dos paneles usan la misma transformación PCA y los mismos ejes; cada color identifica un grupo dentro de su caso y el gris indica ruido. Los colores no establecen correspondencias entre casos.

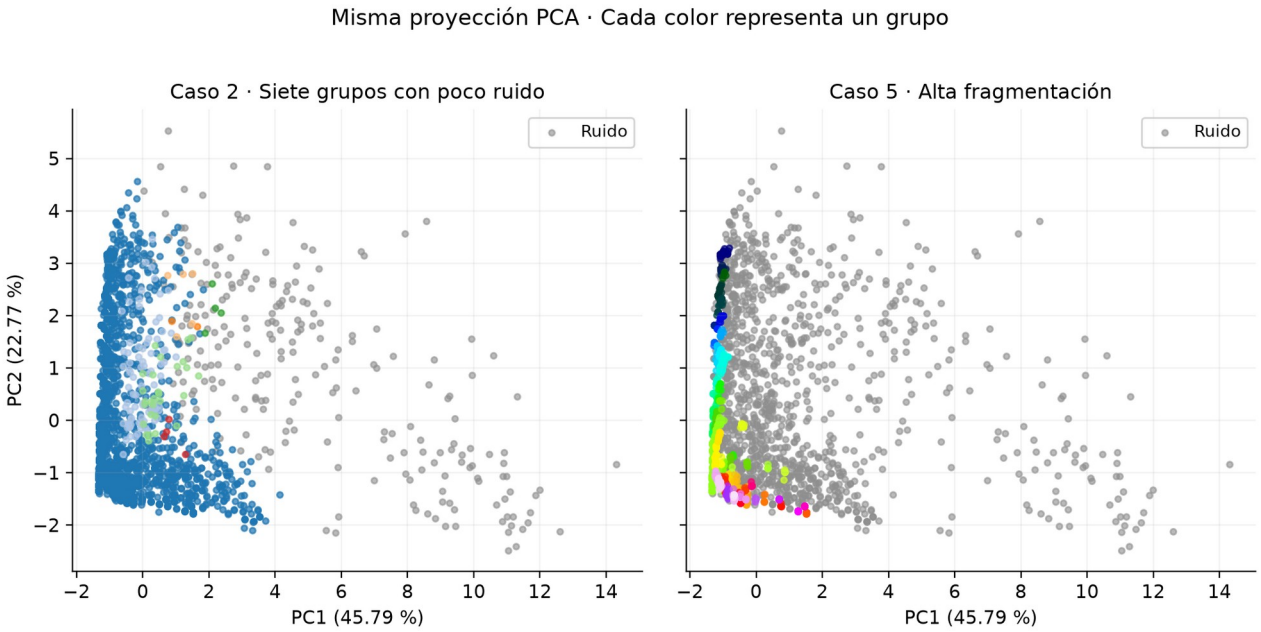


Figura 6 Proyección de los casos 2 y 5. Los dos componentes conservan el 68,57 % de la varianza. DBSCAN se ejecutó sobre los diez atributos, no sobre esta proyección; una superposición en el plano no demuestra coincidencia en el espacio original. Fuente: resultados del proyecto.

En el caso 2 predomina un color, mientras que el caso 5 muestra más grupos y más puntos grises. Las barras complementan esta vista con las cantidades exactas, porque varios alumnos pueden quedar superpuestos en la proyección.

4 Cómo determina DBSCAN la cercanía y los grupos

Cada alumno se representa como un punto en un espacio matemático de diez dimensiones: una coordenada por atributo académico. Antes de comparar alumnos, estandarizamos cada atributo restando su media y dividiendo por su desvío muestral. Así, los días y los conteos se expresan en una escala comparable.

La cercanía se calcula con distancia euclídea: para dos alumnos, se restan sus valores estandarizados en cada uno de los diez atributos, se elevan esas diferencias al cuadrado, se suman y se toma la raíz cuadrada. Son vecinos si esa distancia es menor o igual que eps. Por ejemplo, con eps=0,5, una distancia de 0,4 los incluye en la misma vecindad; una de 0,6 los deja fuera [2].

Un alumno es núcleo si su vecindad contiene al menos min_samples puntos, incluido él mismo. DBSCAN conecta núcleos vecinos y añade como borde a los alumnos cercanos a un núcleo que no alcanzan esa densidad mínima; los que no pertenecen a esas regiones quedan como ruido. Dos alumnos pueden integrar el mismo grupo mediante una cadena de núcleos, aunque no sean vecinos directos. Todo se calcula en diez dimensiones; PCA resume los puntos en dos ejes únicamente para dibujar las figuras [1, 2].

5 Interpretación de los resultados

El grupo gigante refleja continuidad por densidad, no un único perfil académico. DBSCAN conecta núcleos vecinos en los diez atributos estandarizados; los extremos de una cadena pueden ser muy diferentes y pertenecer al mismo grupo. Por eso puede reunir perfiles que otros métodos separan: el grupo de 2.215 alumnos mezcló integrantes de cinco grupos jerárquicos. No medimos cuántas regiones internas lo sostienen [1, 2, 3].

Al reducir eps, algunas conexiones se rompen y la región se fragmenta; otros alumnos pierden densidad o cercanía a un núcleo y pasan a ruido. Aumentar min_samples también puede eliminar regiones pequeñas. El ruido expresa falta de conexión suficiente, no un perfil común ni errores en los datos. Los grupos muy pequeños son posibles porque min_samples exige vecinos para un núcleo, no un tamaño mínimo del grupo final [1, 2].

Las pruebas muestran el costo de separar esa región. De las 470 configuraciones, ocho obtuvieron siete grupos con hasta 15 % de ruido, pero el mayor concentró al menos 94,54 % de los agrupados. En el candidato 1,175/4, cambios pequeños produjeron seis, once o tres grupos. El caso de 59 grupos alcanzó Silhouette de 0,4823, pero evaluó sólo 1.401 de los 2.587 alumnos: una mayor puntuación coexistió con fragmentación y exclusión. Silhouette no basta para valorar la utilidad de los perfiles [1, 3].

No encontramos una combinación convincente de cobertura, perfiles relevantes y sensibilidad aceptable. Retirar deserto no cambió las asignaciones ni el ruido en las cinco configuraciones probadas; eso no identifica qué otros atributos sostienen las conexiones. Descomponer las distancias y examinar las cadenas permitiría orientar cambios de atributos o pesos, pero ese análisis no se realizó. La conclusión se limita al protocolo estudiado [3].

6 Conclusión sobre la incorporación de DBSCAN

Decidimos no adoptar DBSCAN como segmentación académica seleccionada bajo la entrada, distancia y configuraciones evaluadas. Su criterio de conexión reúne perfiles diversos en una región dominante; al exigir mayor separación, aumentan la fragmentación y el ruido. Las soluciones obtenidas no ofrecieron el equilibrio buscado entre perfiles interpretables, cobertura y sensibilidad.

Este resultado no demuestra que exista un único perfil ni que DBSCAN sea inadecuado en general. Cambiar atributos, pesos o distancia podría modificar la estructura, pero requeriría otro experimento. Cerramos la búsqueda de parámetros del protocolo actual y conservamos la implementación, los casos fijos y sus gráficos como evidencia.

Fuentes

[1] scikit-learn. Guía de clustering, secciones DBSCAN y Silhouette. https://scikit-learn.org/stable/modules/clustering.html

[2] scikit-learn. Referencia de sklearn.cluster.DBSCAN. https://scikit-learn.org/stable/modules/generated/sklearn.cluster.DBSCAN.html

[3] Registros del proyecto: docs/resultados/anexo-tecnico-dbscan.md; src/methods/dbscan.py. Casos recalculados para verificar este documento el 10 de octubre de 2026.